

DIAPO 1 — EQUIALGO 2026

DIAPO 2 — LE CONTEXTE

Pourquoi EquiAlgo ?

Les décisions historiques peuvent être influencées par de nombreux facteurs :

- performance académique;
- situation financière;
- contraintes personnelles;
- distance géographique;
- contexte socioéconomique;
- caractéristiques du parcours étudiant.

Problématique

Les données historiques permettent d'entraîner un modèle de Machine Learning. Mais elles peuvent également contenir :

des biais → des inégalités → des décisions historiques difficiles à interpréter

Question

Comment construire un modèle performant tout en évaluant explicitement ses limites et ses biais potentiels ?

DIAPO 3 — LE PROJET EN UN COUP D'ŒIL

De la donnée à l'analyse

01 — DONNÉES

Informations historiques sur les candidats



02 — PRÉTRAITEMENT

Nettoyage + transformations + encodage



03 — MODÉLISATION

Plusieurs algorithmes de Machine Learning



04 — VALIDATION

Validation croisée 10-fold



05 — ÉVALUATION

Accuracy + F1 + ROC-AUC + Log-Loss



06 — AUDIT

Analyse des différences entre groupes

DIAPO 4 — LES DONNÉES

Qu'est-ce que le modèle observe ?

PERFORMANCE ACADÉMIQUE

Cote R Programme

→ Représentation du parcours académique

SITUATION FINANCIÈRE

Revenu familial Indicateurs de besoin

→ Représentation de la situation économique

CONTRAINTES

Heures de travail Distance domicile-campus

→ Contraintes pouvant influencer la situation étudiante

CONTEXTE

Première génération universitaire Région

→ Informations contextuelles

Variable cible

Décision historique d'octroi

DIAPO 5 — UNE PREMIÈRE APPROCHE : CODE 4

Une logique basée sur le classement

Le premier modèle utilisait :

ExtraTrees

Pour prédire les décisions historiques.

Scores construits manuellement

Score de mérite

→ performance académique + autres caractéristiques

Score de besoin

→ revenu + travail + distance + première génération

Puis

Combinaison des scores

-

Ajustement selon certains groupes géographiques

-

Classement des candidats

Résultat

Une approche permettant d'explorer différentes stratégies de classement.

DIAPO 6 — POURQUOI AMÉLIORER LE CODE 4 ?

Le problème n'était pas seulement le modèle.

01 — Risque de fuite d'information

Certaines statistiques étaient calculées avant la validation croisée.

→ Le modèle pouvait indirectement avoir accès à de l'information provenant des données de validation.

02 — Optimisation excessive

Plusieurs paramètres et stratégies étaient comparés sur les mêmes résultats.

→ Risque de choisir une stratégie parce qu'elle fonctionne particulièrement bien sur cet ensemble précis.

03 — Complexité

Plusieurs fichiers de prédictions étaient générés.

→ Plus difficile à analyser et à reproduire.

Objectif

Créer un pipeline plus propre, plus rigoureux et plus facilement auditable.

DIAPO 7 — CODE 5 : NOUVELLE ARCHITECTURE

Une approche plus rigoureuse

Pipeline

Prétraitement

→ imputation → normalisation → encodage

↓

Feature engineering

→ transformations → relations non linéaires → interactions

↓

Machine Learning

→ plusieurs modèles

↓

Validation croisée

→ prédictions OOF

↓

Ensemble

→ probabilités combinées

Principe

Chaque étape doit être apprise uniquement à partir des données d'entraînement du fold.

DIAPO 8 — FEATURE ENGINEERING

Faire ressortir des relations complexes

Les variables brutes ne permettent pas toujours au modèle de représenter toutes les relations.

Transformations non linéaires

Cote R $\rightarrow$ Cote R²

Heures de travail $\rightarrow$ Heures²

Distance $\rightarrow$ Distance²

Revenu $\rightarrow$ log(revenu)

Interactions

Cote R $\times$ revenu

Heures de travail $\times$ distance

Pourquoi ?

Une augmentation de 10 unités n'a pas nécessairement le même effet partout.

Objectif

Donner au modèle davantage de flexibilité sans définir manuellement une règle de décision.

DIAPO 9 — LES MODÈLES

Pourquoi plusieurs algorithmes ?

ExtraTrees

Très flexible

Capture des relations non linéaires et des interactions.

Random Forest

Robuste

Combine plusieurs arbres indépendants.

HistGradientBoosting

Puissant pour les relations complexes

Améliore progressivement les erreurs des modèles précédents.

Régression logistique

Modèle de référence

Simple, interprétable et utile pour comparer les modèles plus complexes.

DIAPO 10 — L'ENSEMBLE

Et si aucun modèle n'était parfait ?

Plutôt que de dépendre d'un seul algorithme :

ExtraTrees

-

Random Forest

-

HistGradientBoosting

-

Régression logistique



ENSEMBLE

Les probabilités produites par les différents modèles sont combinées selon leurs performances.

Intérêt

Réduire la dépendance à un seul modèle

Combiner différentes perspectives

Améliorer la robustesse potentielle

DIAPO 11 — VALIDATION CROISÉE

10-FOLD STRATIFIED CROSS-VALIDATION

Les données sont divisées en **10 groupes**.

À chaque itération

9 groupes

→ entraînement

1 groupe

→ validation

Puis le groupe de validation change.

Après 10 itérations

Chaque observation possède une prédiction réalisée par un modèle qui **ne l'a pas utilisée pour apprendre**.

OOF

Out-Of-Fold predictions

→ base principale pour évaluer le modèle.

DIAPO 12 — COMMENT ÉVALUER LE MODÈLE ?

Une seule métrique ne suffit pas.

ACCURACY

Exactitude globale

→ proportion de prédictions correctes

BALANCED ACCURACY

Équilibre entre les classes

→ particulièrement utile lorsque les classes sont déséquilibrées

F1

Précision + rappel

→ compromis entre les deux

ROC-AUC

Capacité de discrimination

→ distingue les deux classes

LOG-LOSS

Qualité des probabilités

→ pénalise les prédictions très confiantes mais incorrectes

DIAPO 13 — PERFORMANCE ≠ ÉQUITÉ

Le point central d'EquiAlgo

Imaginez un modèle avec une excellente accuracy.

Cela signifie :

Le modèle reproduit bien les décisions historiques.

Mais cela ne signifie pas nécessairement :

Les décisions historiques étaient équitables.

Risque

Biais historique

↓

Apprentissage du biais

↓

Prédiction du biais

↓

Reproduction du biais

Conclusion

Améliorer la performance peut parfois améliorer la reproduction d'un système déjà biaisé.

DIAPO 14 — L'AUDIT D'ÉQUITÉ

Mesurer les différences entre groupes

L'analyse doit être réalisée :

Globalement

Performance globale

ET par groupe

Performance

Distribution des probabilités

Taux de prédiction

Calibration

Écarts entre groupes

Exemple de question

Le modèle présente-t-il la même qualité de prédiction pour différents groupes géographiques ou socioéconomiques ?

Important

L'équité doit être évaluée séparément de la performance prédictive.

DIAPO 15 — RÉSULTAT DU PIPELINE

Une sortie simple

Fichier

predictions/model_scores.csv

Contenu principal

ID candidat

Probabilité prédite

Pourquoi une probabilité ?

Elle permet de :

- comparer les prédictions;
- analyser la distribution des scores;
- évaluer la calibration;
- étudier les différences entre groupes;
- effectuer des analyses supplémentaires.

Avantage

Une sortie unique → analyse plus simple → pipeline plus reproductible

DIAPO 16 — CE QUE LE MODÈLE PERMET

Le modèle peut servir à...

PRÉDIRE

Identifier les tendances présentes dans les données historiques.

COMPARER

Évaluer différents algorithmes.

MESURER

Quantifier les performances avec plusieurs métriques.

ANALYSER

Étudier les probabilités et les différences entre groupes.

AUDITER

Identifier des écarts potentiels.

DIAPO 17 — CE QUE LE MODÈLE NE PEUT PAS GARANTIR

Une prédiction n'est pas une vérité.

Le modèle ne garantit pas :

l'absence de biais

l'équité

l'absence de discrimination

la pertinence des variables historiques

la validité pour une nouvelle population

Pourquoi ?

Parce que :

le modèle apprend à partir des données disponibles.

Si les données contiennent des biais, le modèle peut les apprendre.

DIAPO 18 — LIMITES DU PROJET

Les limites sont aussi importantes que les résultats.

DONNÉES

Les variables disponibles ne représentent pas toute la réalité des candidats.

HISTORIQUE

Les décisions passées peuvent contenir des biais.

GROUPES

Certains groupes peuvent être peu représentés.

MODÈLE

Les modèles complexes sont parfois difficiles à interpréter.

ÉVALUATION

Les performances dépendent du jeu de données utilisé.

CONSÉQUENCE

Les résultats doivent être interprétés avec prudence.

DIAPO 19 — VERS UNE APPROCHE RESPONSABLE

Une utilisation responsable nécessite plusieurs niveaux

01

Performance

Le modèle fonctionne-t-il correctement ?

02

Robustesse

Les résultats restent-ils stables ?

03

Équité

Les différents groupes sont-ils traités de façon comparable ?

04

Transparence

Peut-on expliquer comment le modèle fonctionne ?

05

Supervision humaine

Les résultats sont-ils interprétés par des personnes plutôt que suivis automatiquement ?

DIAPO 20 — CONCLUSION

EQUIALGO 2026

De la prédiction à l'audit

Données historiques



Machine Learning



Validation rigoureuse



Mesure de performance



Analyse d'équité

Message final

Un modèle performant n'est pas nécessairement un modèle équitable.

L'objectif d'EquiAlgo est donc de construire une approche permettant de **mesurer, comparer et questionner** les résultats plutôt que de considérer le modèle comme une boîte noire.

DIAPO 21 — PROCHAINES ÉTAPES

Continuer l'analyse

PERFORMANCE

Comparer les modèles et leurs métriques.

CALIBRATION

Vérifier si les probabilités correspondent réellement aux fréquences observées.

ÉQUITÉ

Comparer les résultats entre groupes.

ROBUSTESSE

Tester la stabilité des résultats selon différents échantillons.

INTERPRÉTABILITÉ

Identifier les variables qui contribuent le plus aux prédictions.

FINALITÉ

Construire un système analysable, transparent et responsable.